

# 基于特征值嵌入的音乐播放列表推荐模型

何 丽<sup>1</sup>, 于 洋<sup>2</sup>

(北方工业大学 计算机学院, 北京 100144)

**摘 要:** 随着数字音乐的蓬勃发展, 为用户提供自动生成的连续播放列表已成为大型音乐平台的重要服务方式之一。传统的基于马尔科夫链的音乐推荐模型在音乐空间向量嵌入的过程中忽略了很多有价值的信息, 比如音乐的特征值、用户的偏好值等。考虑到用户在某一时间段或某一情景会话听同一种类型的音乐的可能性极大, 故本文在马尔科夫链的音乐推荐模型的基础上考虑了音乐特征值对音乐嵌入位置的影响, 提出了一种基于特征值嵌入的音乐播放列表推荐模型。该模型根据用户真实的历史播放列表进行训练, 生成最符合用户当前会话场景的音乐播放列表。最终, 本文通过实验验证了基于特征值嵌入的音乐播放列表推荐模型相较于传统的基于马尔科夫链的音乐推荐模型所推荐的音乐具有更高的相似性, 即更符合用户当前场景需要。

**关键词:** 音乐播放列表 音乐特征值 推荐系统 空间嵌入模型

## Music playlist recommendation model based on feature value embedding

Li He<sup>1</sup>, Yang Yu<sup>2</sup>

(North China Univ. of Tech, Beijing 100144, China)

**Abstract:** With the rapid development of digital music, providing users with automatically generated continuous playlist has become one of the important service methods for large music platforms. The traditional Markov chain-based music recommendation model ignores a lot of valuable information in the process of music space vector embedding, such as the feature value of music, the user's preference value and so on. Considering that the user is very likely to listen to the same type of music in a certain period of time or a certain situation, so this paper considers the influence of music feature value on the music embedding position based on the music recommendation model of Markov chain, and proposed a music playlist recommendation model based on feature value embedding. The model is trained according to the user's real historical playlist to generate a music playlist that best matches the user's current session scene. Finally, the paper verifies that the music playlist recommendation model based on eigenvalue embedding has higher similarity than the music recommended by the traditional Markov chain-based music recommendation model, which is more in line with the user's current scene needs.

**Keywords:** Music playlist, Music feature value, Recommendation system, Space embedding model

收稿日期: 修回日期:

基金项目: 国家自然科学基金项目 (61371143); 北京市教委科研计划面上项目 (KM201510009008)

作者简介: 何丽 (1977--), 女, 硕士生导师, 主要研究方向: 数据库; 于洋 (1993--), 女, 研究生, 主要研究方向: 推荐系统

## 0 引言

音乐的电子存储模式已经彻底改变了音乐的消费方式,庞大的音乐数据在给消费者提供便利的同时,也带来了前所未有的挑战。因此,从大量数据中推荐有效信息给用户已经成为当今大数据研究领域的一大重点。推荐系统已成为各种应用程序的基本组成部分,它的产生使用户省却了查找、搜索等繁杂的工作量,是一种能够方便用户自动获取感兴趣的信息,产品和服务的有效方法。

目前大多数推荐系统都会生成用户最可能喜欢的顶级项目的排名列表,这些系统主要关注孤立的物品属性或用户评分,并倾向于假设用户偏好具有稳定性[1]。然而在现实环境中,用户的喜好总是随着时间、心情等外在因素的变化而变化,评分也并不能真实的反映喜好程度,所以单纯的依赖用户的个人行为并不能产生理想的结果。考虑到音乐推荐的特性,比如用户听一首音乐的时间很短,所以用户在同一个会话场景内会听很多首相似类型的音乐,所以提供一个连续的符合当前会话场景的播放列表来提高用户的听歌体验变得尤为重要。

现在音乐平台上的音乐都按不同形式的播放列表显示[2],苹果和潘多拉这样的公司已经开发出成功的商业播放列表算法,但对于这些算法的工作原理以及它们在严格评估中表现如何的情况知之甚少。尽管有很大的商业需求,但是在播放列表生成的自动化方法(例如[3][4][5][6][7])方面的学术研究却很少。Mitul Sheth 等人利用多项式回归技术、支持矢量机等技术,提出根据用户位置信息推测用户情感,从而将符合情景的音乐组成播放列表推荐给用户[8],但是获取用户情感的算法精确度并不是很高,所以最终的精确度并不理想。李瑞敏等人提出协同标注中的标签包含丰富的个性化描述信息以及项目内容信息,因此可以用来帮助提供更好的推荐[9][10]。Anna Gatzoura 等人使用结合图模型的混合案例推理方法对播放列表推荐进行研究,确定不同种类音乐之间的关系构建相似集。该框架克服了多媒体建议中存在的语义鸿沟,且在冷启动情况下效果更好[1]。Oren Sar Shalom 和 Noam Koenigstein [11]对播放列表推荐进行研究时,他们考虑了点击概率和项目间相互作用,同时通过使用反向倾向评分(IPS)的新颖改进来改进传统的协作过滤算法。B. McFee 和 G. Lanckriet 采用马尔可夫链对播放列表建模[6],并提出了一个受自然语言处理技术启发的评估程序。

由于音乐推荐列表的特殊性,如用户在某一时间段或某一情景会话听同一种类别的音乐的可能性极大。因此,在欧几里得空间中嵌入音乐特征值是非常有必要的。Shuo Chen[12]等人介绍了一种潜在马尔科夫嵌入模型(LME),该模型借鉴了多词汇连续语音识别中常用的N-gram模型的思想,第N个词的出现概率只与前面N-1个词相关,整句出现的概率就是各个词出现概率的乘积。这些概率可以通过直接从语料中统计N个词同时出现的次数得到。虽然这种方法很好的实现了列表的连续性,但是忽视了很多有用的信息,比如音乐的特征值。

针对于LME模型中存在的不足,本文提出了一种基于特征值嵌入的音乐播放列表推荐模型,在保留了LME模型的连贯性的同时考虑了推荐列表中音乐类型的特征值。本文将音乐特征值映射到多维欧几里德空间中,每个音乐就是空间中的一个点,两点之间的距离反映了音乐之间的关系强弱,距离越近说明音乐间的转移概率越大。音乐列表生成过程示意图如下,其中S代表音乐,U代表用户。




图 1 音乐列表推荐示意图

## 1 基于特征值嵌入的音乐播放列表推荐模型

基于特征值嵌入的音乐播放列表推荐模型的原理是：使用用户历史播放列表数据进行训练，然后将音乐的特征属性值在欧几里得空间中进行向量表示，再通过音乐间距离长短表示音乐间转移概率的大小，最终生成连续的音乐播放列表。

### 1.1 基于特征值的音乐嵌入方法

LME 模型认为播放列表是具有序列性质的，因此提出假设：播放列表具有一阶马尔科夫特性，即下一首音乐的选择仅与当前音乐有关，而与其它任何音乐没有任何关系，通过统计语料库中  $n$  个词同时出现的次数相乘，从而得到一句话出现的概率，LME 模型就是根据此思想作为基础。将音乐映射到欧式空间中，音乐的向量在空间中的相对距离与音乐间的转移概率有关。音乐特征向量之间的距离越近，转移概率越大，在播放列表中作为下一首歌出现的概率越高。为了对音乐播放列表进行自然的描述，根据 N-gram 模型采用一阶马尔科夫模型对播放列表进行建模[15][16]，一首音乐相当于一个单词，一个收听列表比作是一句话。那么当历史播放列表已经存在的情况下，每首音乐的转移概率的乘积必然是极大值，所以根据历史用户听歌列表训练模型，就可以得到音乐在欧几里得空间中的坐标向量。具体计算方式如下：

本文的目标是根据嵌入模型，在特定情境下为用户生成连贯的播放列表。现给定音乐集合  $S = \{s_1, s_2, \dots, s_n\}$ ，音乐列表集合  $P = \{p_1, p_2, \dots, p_n\}$ ，正如[13]中提到的，某一个音乐列表  $p_i$  生成的概率可以转化成列表中相邻两首音乐的转移概率相乘，概率越大说明两首音乐的相似性越高，转移概率又是通过两首音乐间的空间映射距离得出。设音乐  $i-1$  到音乐  $i$  的转移概率为  $\Pr(s^{(i)} | s^{(i-1)})$ ，那么播放列表的转移概率如公式（1）所示。

$$\Pr(p) = \prod_{i=1}^n \Pr(s^{(i)} | s^{(i-1)}) \quad (1)$$

在欧几里得空间中，每一首音乐都被表示成空间中的点，每两首音乐之间的转移率都与音乐在空间中的映射点之间的距离有关，也就是说距离越近的两首歌的关联程度越大，转移率也就越大，示意图如下。




图2 音乐距离示意图

在图中， $S(i-1)$ 与 $S(i)$ 的距离更近，所以选择音乐  $i-1$  后选择  $i$  的概率更大。在欧几里得空间中，假设音乐的坐标表示为向量  $X(s)$ ，那么音乐  $i-1$  到音乐  $i$  之间的欧氏距离为  $\|X(s^{(i)}) - X(s^{(i-1)})\|_2^2$ ，那么音乐  $i-1$  到音乐  $i$  的转移概率描述如公式 (2) 所示。

$$\Pr(s^{(i)} | s^{(i-1)}) = \frac{e^{-\frac{\|X(s^{(i)}) - X(s^{(i-1)})\|_2^2}{2}}}{\sum_{j=1}^{|S|} e^{-\frac{\|X(j) - X(s^{(i-1)})\|_2^2}{2}}} \quad (2)$$

其中， $X(s^{(i)})$ 表示播放列表中的音乐  $i$  的坐标表示向量， $\|X(j) - X(s^{(i-1)})\|_2^2$ 表示列表中音乐  $i-1$  到列表外其他音乐的距离，那么播放列表的转移概率如公式 (3) 所示。

$$\Pr(p) = \prod_{i=1}^n \Pr(s^{(i)} | s^{(i-1)}) = \prod_{i=1}^n \frac{e^{-\frac{\|X(s^{(i)}) - X(s^{(i-1)})\|_2^2}{2}}}{\sum_{j=1}^{|S|} e^{-\frac{\|X(j) - X(s^{(i-1)})\|_2^2}{2}}} \quad (3)$$

为了将音乐嵌入到空间中，本文使用现有的历史播放列表样本  $D = (P_1, P_2, \dots, P_m)$  作为训练数据。由于历史的播放列表已经存在，所以根据该历史播放列表所求出的转移概率是极大值，由此可计算出音乐在空间中的位置，表达如公式 (4) 所示。

$$X = \arg \max_{p \in D} \prod_{i=1}^n \frac{e^{-\frac{\|X(s^{(i)}) - X(s^{(i-1)})\|_2^2}{2}}}{\sum_{j=1}^{|S|} e^{-\frac{\|X(j) - X(s^{(i-1)})\|_2^2}{2}}} \quad (4)$$

利用最大似然估计法不断迭代至最优，求出所有音乐的坐标向量矩阵。为了实现推荐的音乐列表符合用户当前听歌情景的目标，本文向音乐的特征矩阵添加  $k$  个音乐特征值的维度，将音乐特征值嵌入到坐标矩阵中，从而影响音乐嵌入到空间中的位置，达到相似类型的音乐在空间中的距离较近的结果。如音乐 A 有三个标签“安静”，“王菲”和“1980s”，音乐 B 有三个标签“安静”，“梁静茹”和“1980s”，音乐 C 有三个标签“摇滚”，“周杰伦”和“流行”，那么音乐 A 与音乐 B 的向量坐标相似，所以在欧几里得空间中距离更近，那么当用用户 U 选择了听取音乐 A 后，该模型经过距离的计算，就会给用户 U 推荐音乐 B 作为下一首音乐播放，而不会选择距离较远的音乐 C。

## 1.2 推荐列表生成

本文根据用户历史播放列表，通过基于特征值的音乐嵌入方法将音乐映射到欧氏空间中。本文最终的目标是通过音乐在欧几里得空间中的距离计算音乐间的转移概率，最终为用户生成一个符合用户当前会话情景的顺序音乐播放列表。首先，本文给定一首音乐  $s_{current}$ ，即用户第一次听音乐时选取的音乐，播放列表的开始位置确定后，根据基于特征值的音乐嵌入方法获得带有音乐特征属性的音乐嵌入空间的向量坐标，然后根据欧式空间两点的距离公式，找到离  $s_{current}$  最近的音乐映射点，最终得到音乐  $s_{next}$ 。反复以上步骤，直至生成的播放列表长度为设定阈值为止。

为了更好的为用户个性化的推荐顺序列表，本文除了对音乐的特征属性值嵌入到空间中，还考虑了用户对音乐的长期偏好参数，所以本文将在公式中嵌入一个用户的长期偏好系数  $\theta_{(u,s)}$ ，如公式 (5) 所示。

$$X(s_{next}) = \arg \min_{s \in S} [\theta_{(u,s)} (\|X(s_{current}) - X(s)\|_2^2)] \quad (5)$$

其中  $\theta_{(u,s)}$  表示某一用户  $u$  对某一首音乐  $s$  的偏好值，这个偏好系数可以使所有欧几里得空间中的备选音乐  $s$  在空间模型中与  $s_{current}$  的距离变得更近。 $\theta_{(u,s)}$  表达式如公式 (6) 所示：

$$\theta_{(u,s)} = \begin{cases} 1, & \text{不喜欢} \\ 0.5, & \text{喜欢} \end{cases} \quad (6)$$

其中，用户对音乐的喜好值是根据用户对音乐的收藏情况来判定的。重复上述过程，直至得到一个连续排列的音乐播放列表，以给定数量的音乐向用户推荐或遍历嵌入模型中产生的所有音乐停止。

## 2 实验

### 2.1 实验数据

本文的实验的数据数据集是来自 Last.fm 音乐网站爬取到的真实数据，爬虫采用现在最流行的基于 java 语言的 WebMagic 爬虫框架，本文应用的爬虫主要应用了两个包，Webmagic-core 和 Webmagic-extension，这两部分包含了爬虫基本模块、基本抽取器、注解格式定义爬虫、JSON、分布式等支持。

从采集的数据中选取 1899 个活跃用户，筛选出拥有从 2018 年 1 月到 2018 年 6 月期间的历史播放列表，并将播放列表中出现的所有音乐的标签及用户的偏好值记录下来。为了减少数据噪音的影响，本文清除播放列表中音乐少于 5 首的列表及在数据集中出现次数少于 20 次的音乐，仅保留标签出现次数前 20 的标签。实验将数据分为训练数据和测试数据进行实验，确保测试数据集的所有音乐出现在训练数据集中，以确保所有音乐在空间中有位置标记。统计数据表如下：

表 1 统计数据表

名称	数据量	训练数据	测试数据
用户	1899	1021	870
音乐	21,758	21,758	21,,758
播放列表	1269	836	182
标签	20	20	20

其中，每个用户拥有多条播放列表，每个播放列表包含多首音乐，每首音乐包含多个音乐特征属性值。

### 2.2 实验结果分析

实验一，由于本文在空间维度中加入了音乐特征值，通过音乐特征值影响了音乐在空间中的位置，所以所呈现出的结果应该是同类型或相似类型的音乐距离较近，即所得出的音乐推荐列表中，音乐之间的特征相似度应该高于 LME 模型，所以本文对比了基于特征值嵌入的音乐播放列表推荐模型和 LME 模型的音乐推荐列表的相似度。设定音乐特征值空间维度  $d$  分别取  $d=0$ ,  $d=2$ ,  $d=5$ ,  $d=10$ ,  $d=20$ ，音乐列表长度  $n=30$ ，其中  $d=0$  即代表音乐空间向量矩阵中未嵌入音乐特征值，相似度系数如公式 (7) 所示。

$$J = \frac{\sum_{i=1}^{n-1} |E^i \cap E^{i+1}|}{\sum_{i=1}^{n-1} |E^i \cup E^{i+1}|} \quad (7)$$

其中， $n$  为播放列表长度， $E^i$  为列表中第  $i$  首歌曲的特征值集合， $J$  为该播放列表中两两音乐之间的 Jaccard 系数之和，即代表播放列表的相似度。实验对比结果如图 3 所示：






图3 实验结果展示图

由实验结果可知,没有嵌入音乐特征维度的播放列表的 Jaccard 系数很低,即所推荐的列表中,相似的音乐出现几率极小。随着嵌入音乐特征维度的增加,推荐列表中音乐的相似度越高,那么说明基于特征值嵌入的音乐播放列表推荐模型确实提高了推荐列表中相似音乐的比例,达到了当用户选择一首音乐的时候,向用户推荐与该音乐类型相似的音乐列表。

### 3 总结

由于传统的 LME 模型并未考虑音乐特征属性对用户选择音乐的影响,所以本文提出了一种改进了的 LME 嵌入模型,在该模型中,根据用户历史播放列表将音乐的特征属性值被嵌入到多维欧几里得空间中,通过计算音乐之间的距离反映它们之间关系的强弱,即转移概率的大小,从而根据单一的最优解最终得到连续的最优音乐推荐列表。

本文基于爬取的 last.fm 真实数据进行了多次试验,相比较传统的马尔科夫嵌入模型,本文提出的模型展现出了推荐播放列表的音乐在音乐特征属性方面具有更高的相似度,该空间模型方法有效地利用了收听列表中音乐类型之间的联系,能够为用户提供连续的符合用户当前会话需求的音乐推荐列表。

虽然本文提出的推荐模型在一定程度上使音乐推荐列表具有更高的相似度,但是在训练过程中也发现了一些问题。如本文所提出的模型的一次迭代的时间比 LME 模型长并且时间复杂度也有所提高。除此之外,实验中发现随着特征维度的增加,对推荐列表音乐相似度的影响相对越来越小,当到达一定值时甚至出现下滑的趋势。本文猜测是与特征值分类策略有关,所以本文将继续对音乐特征值类聚方面做研究,将庞大的特征库进行类聚,使具有相似类型,但不同名称的音乐特征属性进行聚类划分,再将划分后的结果进行特征维度的扩充。

该模型具有良好的延展性,除了扩展音乐特征属性,还可以嵌入复杂的用户偏好、社会信息(朋友关系、用户画像)、地理位置信息等。在音乐推荐的过程中,还可以考虑建立一些参数去改变某一部分对音乐推荐影响因子的权重,将不同的影响因子进行高效混合,已达到更加符合用户需求的目的。Dietmar Jannach 等人[14]还证明了不同的长期偏好会帮助提高不同维度的播放列表的质量。吕成成[15]提出了一种基于用户项目属性偏好的鲁棒协同过滤推荐算法,在用户共同评分项匮乏的情况下也可以根据相同的项目属性偏好度量用户相似性,缓解评分数据稀疏性。所以本实验还可继续就偏好值与用户项目属性偏好这些参数进行突破。

### 参考文献

- [1] Gatzoura A, Sánchez-Marrè M. A case-based reasoning framework for music playlist recommendations[C]//2017 4th International Conference on Control, Decision and Information Technologies (CoDIT). Barcelona – Spain: IEEE, 2017: 0242-0247.
- [2] Bonnin G, Jannach D. Automated Generation of Music Playlists: Survey and Experiments[J]. ACM Computing Surveys, 2014, 47(2):1-35.
- [3] Aizenberg N, Koren Y, Somekh O. Build your own music recommender by modeling internet radio streams[C]//Proceedings of the 21st international conference on World Wide Web. New York: ACM, 2012: 1-10.

- [4] 滕少华, 郑明, 刘冬宁. 面向音乐推荐的全变差图非负矩阵分解方法[J]. 计算机应用研究, 2018, 35(4): 1010-1013.
- [5] Maillet F, Eck D, Desjardins G, et al. Steerable Playlist Generation by Learning Song Similarity from Radio Station Playlists[C]// The International Society of Music Information Retrieval. Kobe, Japan: 2009: 345-350.
- [6] McFee B, Lanckriet G R G. The Natural Language of Playlists[C]// The International Society of Music Information Retrieval. Miami, Florida (USA): 2011, 11: 537-542.
- [7] Platt J C. Fast embedding of sparse similarity graphs[C]//Advances in neural information processing systems. Montreal, Canada: 2004: 571-578.
- [8] Gajjar K, Shah S. Mood based Playlist Generation for Hindi Popular Music: A Proposed Model[J]. International Journal of Computer Applications, 2015, 127(14): 11-14.
- [9] 李瑞敏, 林鸿飞, 闫俊. 基于用户-标签-项目语义挖掘的个性化音乐推荐[J]. 计算机研究与发展, 2014, 51(10):2270-2276.
- [10] 闫俊, 刘文飞, 林鸿飞. 基于标签混合语义空间的音乐推荐方法研究[J]. 中文信息学报, 2014, 28(4):117-122.
- [11] Sar Shalom O, Koenigstein N, Paquet U, et al. Beyond collaborative filtering: The list recommendation problem[C]//Proceedings of the 25th International Conference on World Wide Web. International World Wide Web Conferences Steering Committee. San Francisco (USA): 2016: 63-72.
- [12] Chen S, Moore J L, Turnbull D, et al. Playlist prediction via metric embedding[C]//Proceedings of the 18th ACM SIGKDD international conference on Knowledge discovery and data mining. San Francisco, United States: ACM, 2012: 714-722.
- [13] Jin L, Yuan D, Zhang H. Music recommendation based on embedding model with user preference and context[C]//Big Data Analysis (ICBDA), 2017 IEEE 2nd International Conference. Beijing, China: IEEE, 2017: 688-692.
- [14] Jannach D, Kamehkhosh I, Lerche L. Leveraging multi-dimensional user models for personalized next-track music recommendation[C]//Proceedings of the Symposium on Applied Computing. San Francisco, United States: ACM, 2017: 1635-1642.
- [15] 吕成成. 基于用户项目属性偏好的协同过滤推荐算法[J]. 计算机技术与发展, 2018, v.28; No.252(04):160-164+168.